BÁO CÁO BÀI TẬP LỚN – MÔN HỌC MÁY

Học kỳ 1, năm học 2026–2027

21.165 ảnh · 4 lớp · mô hình học máy cổ điển

Phân loại ảnh X-quang lồng ngực bằng học máy cổ điển và đánh giá nguy cơ shortcut learning trên bộ dữ liệu COVID-19 Radiography

GVHD: TS. Lê Anh Nhã Uyên

Lớp Khoa học máy tính 2024 — Nhóm 10

Trường Đại học Kỹ thuật – Công nghệ Cần Thơ (CTUT)

Khoa Công nghệ Thông tin và Truyền thông

Cần Thơ, tháng 11/2026

SINH VIÊN THỰC HIỆN

Trần Nguyễn Đức	KHMT2411011	Nguyễn Vũ Thương	KHMT2411022
Lê Hải Lý	KHMT2411021	Nguyễn Trần Minh Thuận	KHMT2411014
Phạm Lê Minh	KHMT2411003	Hàng Thái Tú	KHMT2411046

Ba câu hỏi, sáu chương, ba điểm mang về

SÁU CHƯƠNG BÁO CÁO

Ch.1
Đặt vấn đề

Ch.2
Dữ liệu và phương pháp

Ch.3
Kết quả RQ1 và RQ2

Ch.4
Mô hình nhìn vào đâu

Ch.5
Kiểm chứng và triển khai

Ch.6
Giới hạn và kết luận

BA ĐIỂM MANG VỀ

T1
152 đặc trưng thủ công với SVM RBF đạt macro-F1 vượt xa hai mốc nền.

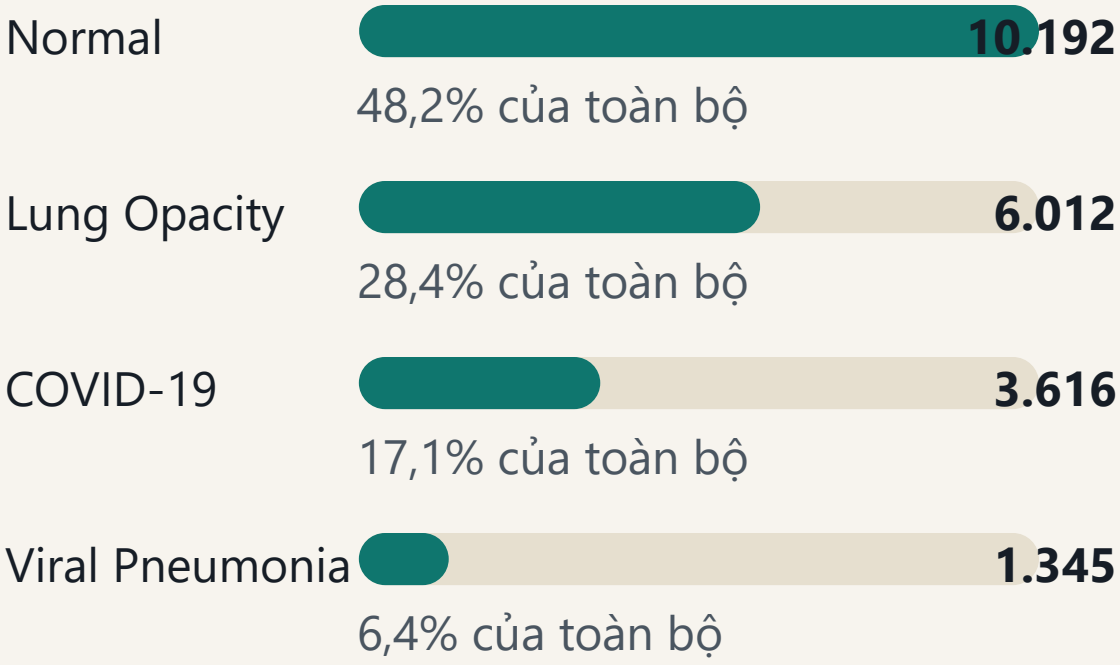
T2
Mô hình chỉ nhìn ngoài phổi vẫn giữ được phần lớn năng lực phân loại.

T3
Kết quả chỉ có giá trị trong phạm vi bộ dữ liệu này, không dùng để chẩn đoán.

Nguồn: report/README.md · slides/texts.py (T1–T3) · results/

21.165 ảnh, bốn lớp, lớp đông nhất gấp 7,6 lần lớp hiếm nhất

PHÂN BỐ BỐN LỚP



21.165
ảnh trong bộ dữ liệu gốc

7,6×
tỉ lệ Normal trên Viral Pneumonia

Đoán toàn bộ là Normal: 0,1627 (B0).

Nguồn: splits/split_v1.csv · results/b0_majority/metrics.json

Ba câu hỏi và một ranh giới: chỉ học máy cổ điển

RQ1

Nhóm đặc trưng nào lấy được tín hiệu nhất?

Bốn nhóm: histogram, GLCM+LBP, HOG, ghép; so bằng macro-F1 và CI 95%.

RQ2

Bộ phân loại nào phù hợp với 152 chiều đặc trưng?

Sáu bộ trên cùng vectơ; siêu tham số chọn bằng 5-fold CV. DT, RF, GB chạy ba seed.

RQ3

Che và cắt vùng phổi có làm đổi macro-F1 không?

Năm kịch bản: huấn luyện và đánh giá cùng một chế độ ảnh, đo lại trên cùng tập.

RANH GIỚI H7

Chỉ dùng học máy cổ điển với đặc trưng thủ công — không Deep Learning (mạng nơ-ron); ảnh gốc xám 299×299, không dữ liệu ngoài bộ đã công bố.

Nguồn: results/threshold_v3.md mục 1 · report/01 mục 1.4

Nhãn lớp không độc lập với nguồn ảnh

Rahman và cộng sự (2021) — bộ COVQU

18.479

COVID 3.616 · Lung Opacity 6.012 · Normal 8.851 (nhóm RSNA)

Mooney et al. — Normal

1.341

mẫu Normal ghi nhãn từ bộ Chest X-Ray Images (Pneumonia)

Mooney et al. — Viral Pneumonia

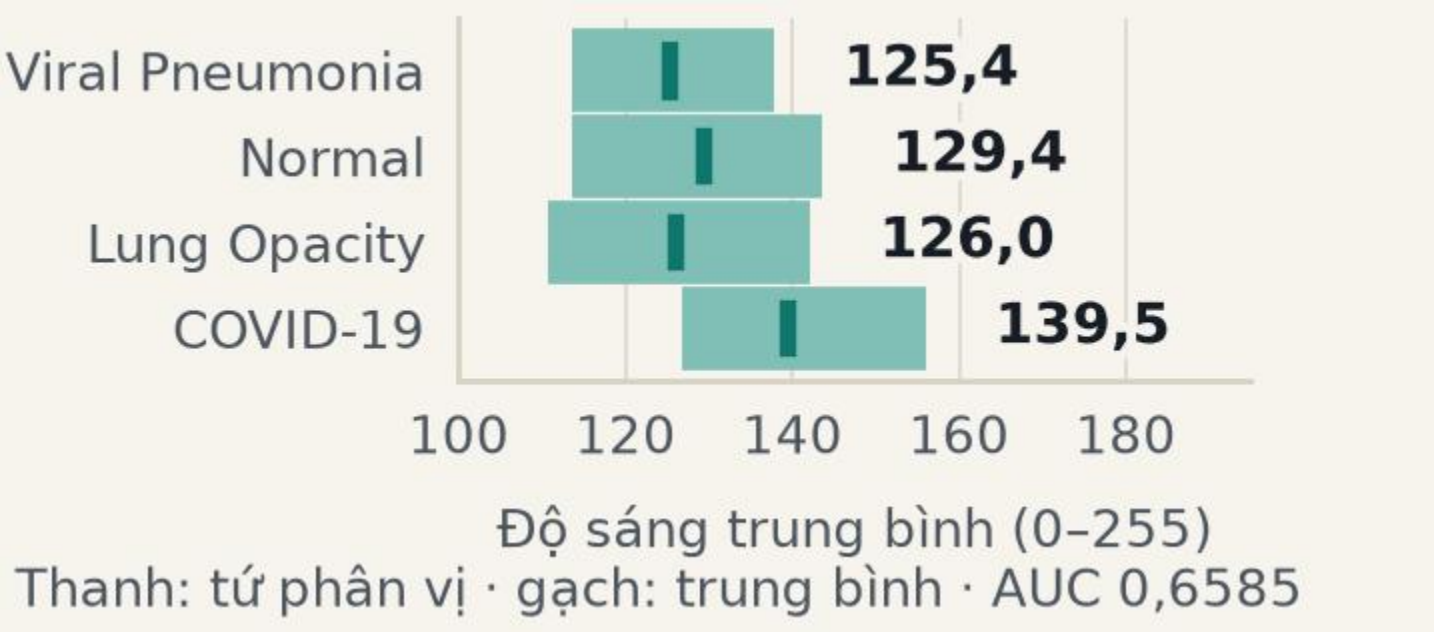
1.345

toàn bộ lớp Viral Pneumonia đến từ một nguồn

21.165 ảnh ghép từ nhiều nguồn công bố; 2.686 ảnh thuộc bộ Kaggle của Mooney. Cùng nhãn Normal, hai nguồn có thể khác thiết bị, dải sáng và tỉ lệ bệnh.

Nguồn: results/eda/normal_source_labels.csv · splits/split_v1.csv · docs/dataset_provenance.md mục 2.1

A0 chỉ đọc metadata tệp, không nhìn ảnh: 0,2397



Khoảng tứ phân vị và giá trị trung bình của bốn lớp.

AUC COVID/nền

0,6585

phân biệt COVID nhờ độ sáng trung bình

A0 (chỉ metadata)

0,2397

chỉ đọc thuộc tính tệp, không nhìn ảnh; B0 đoán toàn bộ là Normal

Nguồn: results/eda/brightness_by_class.csv · results/a0_shortcut, b0_majority/metrics.json · results/threshold_v3.md mục 3

Trùng tuyệt đối bị chặn, gần trùng thì không

BA TẬP SAU KHI TÁCH NHÓM

14.815	3.174	3.176
train	val	test

178 nhóm trùng tuyệt đối

401 ảnh nằm trong các nhóm này; nhóm trùng khác nhãn: 0.

Cùng một nhóm pHash tuyệt đối bị ép về một tập, nên không thể xuất hiện ở cả hai.

735 cặp gần trùng nằm khác tập

test–train 325 · train–val 335 · test–val 75; trong đó 229 cặp lệch nhãn.

Cặp có khoảng cách Hamming ≤ 4 trong toàn bộ dữ liệu: 1.570.

SHA-256 f99e03d3d5cfc32f2bbc9bef…

băm của splits/split_v1.csv, ghi trong biên bản mở khóa test.

Nguồn: splits/README.md mục 3 · splits/split_v1.csv

152 chiều thủ công, chuẩn hóa chỉ trên train

Ảnh gốc
xám 299×299
một kênh, không resize lại

Histogram
64 chiều
phân bố mức xám

GLCM + LBP
88 chiều
texture hai vùng

Ghép
152 chiều
ba khối cùng một vectơ

Chuẩn hóa
fit trên train
scaler học 14.815 ảnh

SVM RBF
bộ phân loại
mô hình đóng băng, một seed

HOG ĐO RIÊNG

10.404 chiều

HOG sinh nhiều chiều nhất nhưng là nhóm yếu nhất: macro-F1 0,7625. Chi phí do phép trích: HOG 10.404 chiều 0,0201 s/ảnh, GLCM+LBP 88 chiều 0,0552 s/ảnh.

Nguồn: src/features_*.py · report/02 mục 2.6–2.7 · results/report_rq1/r1_summary.csv

Sáu bộ phân loại, một thước đo duy nhất

SÁU BỘ PHÂN LOẠI TRÊN CÙNG VECTƠ 152 CHIỀU

1. Logistic Regression
2. k-NN
3. Decision Tree
4. Random Forest
5. Gradient Boosting
6. SVM RBF

GIAO THỨC ĐO

Siêu tham số	5-fold StratifiedGroupKFold
Seed	42 · 43 · 44 cho DT, RF, GB
Bootstrap	2.000 lần, CI 95% mỗi F1
Quy ước nhóm	$\Delta \geq 0{,}005$ và CI không chứa 0
Tham chiếu	Random Forest của RQ1

SVM tất định, chạy một lần; siêu tham số chọn từ 4 ứng viên bằng 5-fold CV. Mỗi con số trong chương 3 là macro-F1 trên 3.174 ảnh validation.

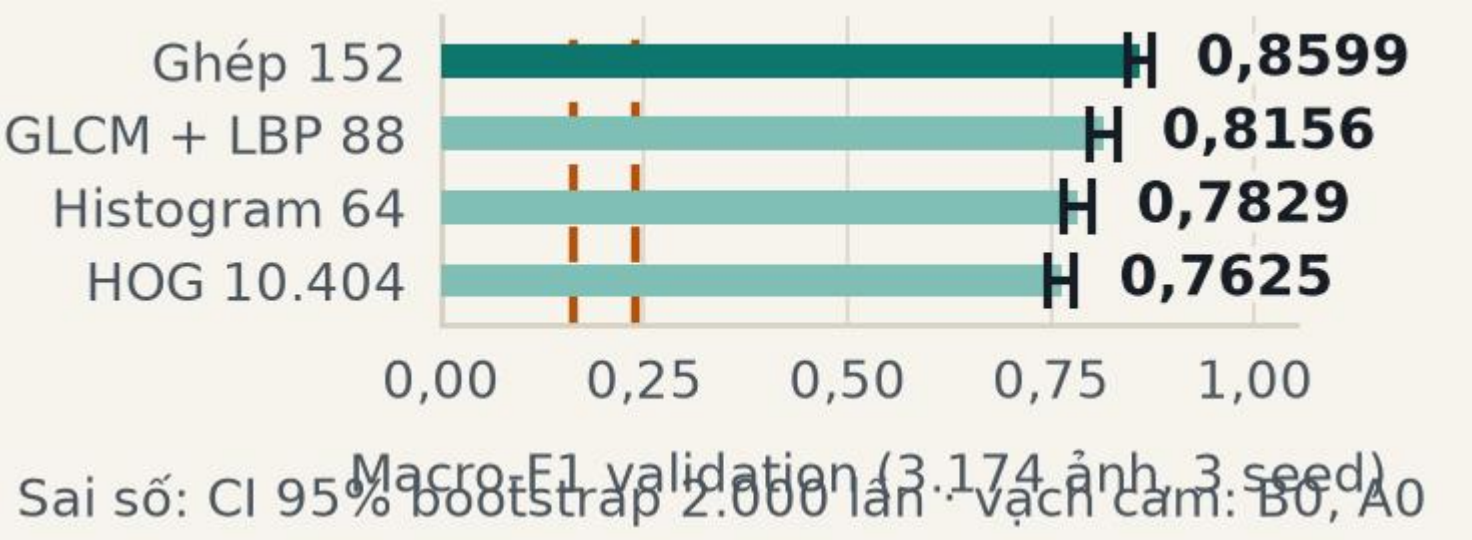
Nguồn: results/report_rq2/r1_summary.csv · results/report_rq2/r1_bootstrap_vs_reference.csv · results/threshold_v3.md mục 3 và 5

CHƯƠNG 3

Kết quả trên 3.174 ảnh validation

Câu hỏi 1: nhóm đặc trưng nào lấy được tín hiệu nhất. Câu hỏi 2: bộ phân loại nào phù hợp với 152 chiều đặc trưng.

Nhóm ghép dẫn đầu với 0,8599 ± 0,0030



Hai mốc nền B0 = 0,1627 và A0 = 0,2397 nằm ngoài khoảng tin cậy của cả bốn nhóm đặc trưng. RQ1 đo với Random Forest cố định 500 cây, không tinh chỉnh siêu tham số.

Ghép 152 chiều · CI [0,8452; 0,8732]

0,8599

GLCM + LBP 88 · CI [0,7986; 0,8309]

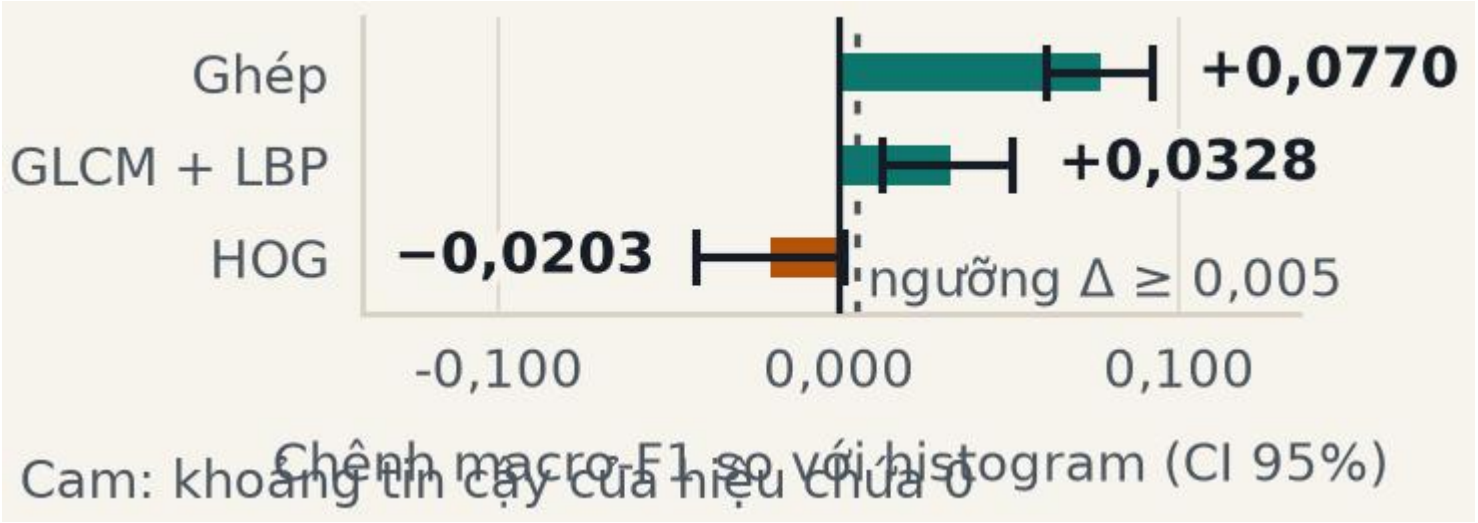
0,8156

Histogram 64 · CI [0,7643; 0,8002]

0,7829

Nguồn: results/report_rq1/r1_summary.csv · results/b0_majority, a0_shortcut/metrics.json

Chỉ ghi nhận “tốt hơn” khi Δ ≥ 0,005 và CI không chứa 0



Chi phí do phép trích quyết định, không do số chiều: HOG 10.404 chiều tốn 0,0201 s/ảnh, GLCM + LBP 88 chiều tốn 0,0552 s/ảnh. Cam = khoảng tin cậy chứa 0.

Ghép − Histogram · [0,0611; 0,0925]

+0,0770

GLCM + LBP − Histogram • [0,0131; 0,0513]

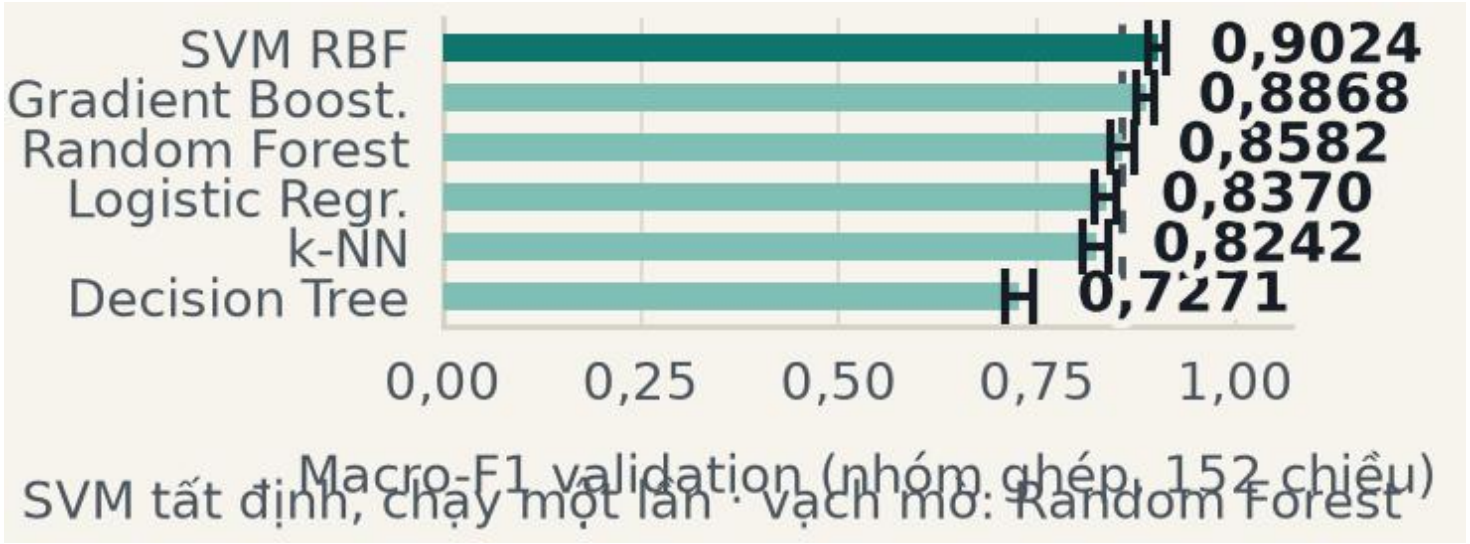
+0,0328

HOG − Histogram · [−0,0419; 0,0014]

−0,0203

Nguồn: results/report_rq1/r1_bootstrap_vs_reference.csv · results/rq1_cost_rank_record.md

SVM RBF 0,9024, hơn Random Forest 0,0442



Δ SVM − RF = +0,0442 [0,0320; 0,0580]; validation còn 349 lỗi, 268 lỗi thuộc cặp Normal ↔ Lung_Opacity. RF ở RQ2 chọn siêu tham số bằng CV (0,8582), khác RF cố định ở RQ1 (0,8599).

SVM RBF · CI [0,8909; 0,9129]

0,9024

Random Forest · CI [0,8432; 0,8716]

0,8582

Decision Tree · CI [0,7090; 0,7449]

0,7271

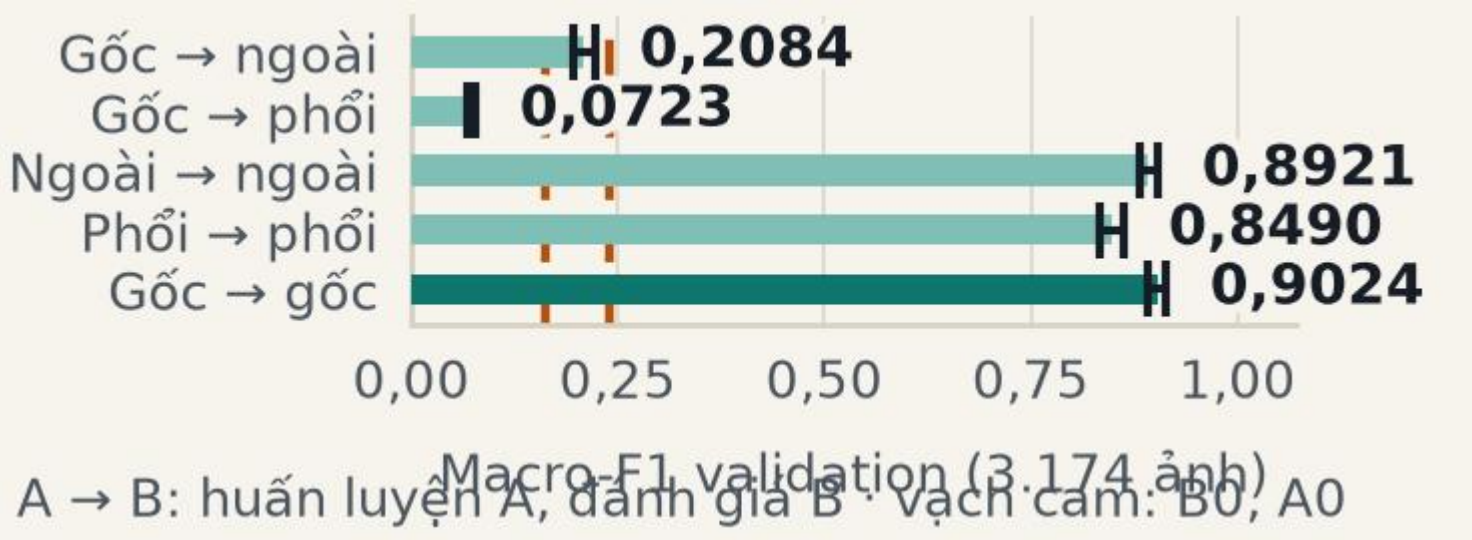
Nguồn: results/report_rq2/r1_summary.csv · results/report_rq2/r1_bootstrap_vs_reference.csv

CHƯƠNG 4

Nếu che mất vùng phổi thì sao?

Câu hỏi 3: che và cắt theo mask phổi có làm đổi macro-F1 không. Năm kịch bản: huấn luyện và đánh giá cùng một chế độ ảnh, rồi đo lại trên cùng 3.174 ảnh validation. Kịch bản cho biết vùng đó có đủ tín hiệu không, không cho biết mô hình gốc dựa vào đâu.

Giữ lại vùng phổi làm mất 0,0535



Quy ước A → B: huấn luyện trên ảnh dạng A, đánh giá trên ảnh dạng B. Chỉ phổi thua gốc −0,0535; chỉ ngoài phổi thua chỉ phổi −0,0431 [−0,0582; −0,0281] — không chứa 0.

Gốc → gốc · CI [0,8909; 0,9129]

0,9024

Chỉ phổi → chỉ phổi · CI [0,8333; 0,8625]

0,8490

Ngoài phổi → ngoài phổi · CI [0,8807; 0,9031]

0,8921

Nguồn: results/report_rq3/r1_summary.csv · results/report_rq3/r3_shortcut_bootstrap.csv

Che sạch phổi vẫn còn 0,8921 macro-F1



Ba chế độ của một ảnh validation
Ảnh gốc · chỉ giữ vùng phổi · chỉ giữ vùng ngoài phổi. Cả ba đều là ảnh split val; chưa đủ căn cứ để nói vùng phổi là nguồn tín hiệu duy nhất.

Ảnh gốc (gốc → gốc)

0,9024

Chỉ vùng ngoài phổi
(ngoài phổi → ngoài phổi)

0,8921

Δ +0,0103 [−0,0017; 0,0220]
khoảng tin cậy của hiệu chứa 0

Nguồn: results/report_rq3/r3_shortcut_bootstrap.csv · results/rq3_mask_check/ · slides/assets/mask_trio.png

GLCM cao nhất khi chỉ nhìn trong phổi: 0,4960



GLCM ngoài phổi 0,3526 và LBP 0,3590: chênh 0,0064, nhỏ hơn độ lịch 0,0103 của 10 lần xáo trộn. Mức giảm chưa chuẩn hóa theo cỡ khối (60 chiều so với 28).

Chỉ phổi · GLCM 60 chiều

0,4960

Ngoài phổi · LBP 28 chiều

0,3590

Ngoài phổi · Histogram 64 chiều

0,2656

Nguồn: results/rq3_permutation_importance.csv

Ba giả thuyết, bốn câu hỏi cần bằng chứng

BA GIẢ THUYẾT (CHƯA KIỂM CHỨNG)

Tuổi nhi

Giải phẫu lồng ngực trẻ nhỏ

Ký hiệu thiết bị

Dấu vận máy chụp ngoài vùng phổi

Dịch chuyển phân phối

Che vùng làm đổi phân phối đặc trưng

DỰ ĐOÁN NẾU ĐÚNG · BẰNG CHỨNG CẦN

1. Ngoài phổi tụt dưới A0
2. Test ngoài CI của val
3. Hiệu có CI chứa 0
4. Xáo trộn không đổi điểm

Quy tắc D4: Mọi lời giải thích về sự khác biệt giữa val và test đều là giả thuyết chưa kiểm chứng, không nêu nguyên nhân.

Nguồn: report/04_hoc_loi_tat_rq3.md mục 4.3 · results/threshold_v3.md (R3) · results/final_test/r5_gioi_han.md

CHƯƠNG 5

Một lần mở khóa, ba lớp kiểm chứng

Mở khóa tập test đúng một lần; trước khi mở, ba lớp kiểm chứng đã chạy: băm split, băm artifact và bộ kiểm thử.

0,8714 trên 3.176 ảnh test

0,8714

macro-F1 trên tập test

Khoảng tin cậy 95%

[0,8579; 0,8840]

Accuracy

86,56%

Tập test chỉ được mở một lần, sau khi mô hình và tham số đã đóng băng; macro-F1 trên validation là 0,9024. 427 trong 3.176 ảnh test bị đoán sai.

Nguồn: results/final_test/final_test_report.json, metrics.json

Val 0,9024, test 0,8714: chênh 0,0310 — chỉ là quan sát



Khoảng tin cậy 95% của macro-F1 test và giá trị điểm.

Validation (3.174 ảnh)

0,9024

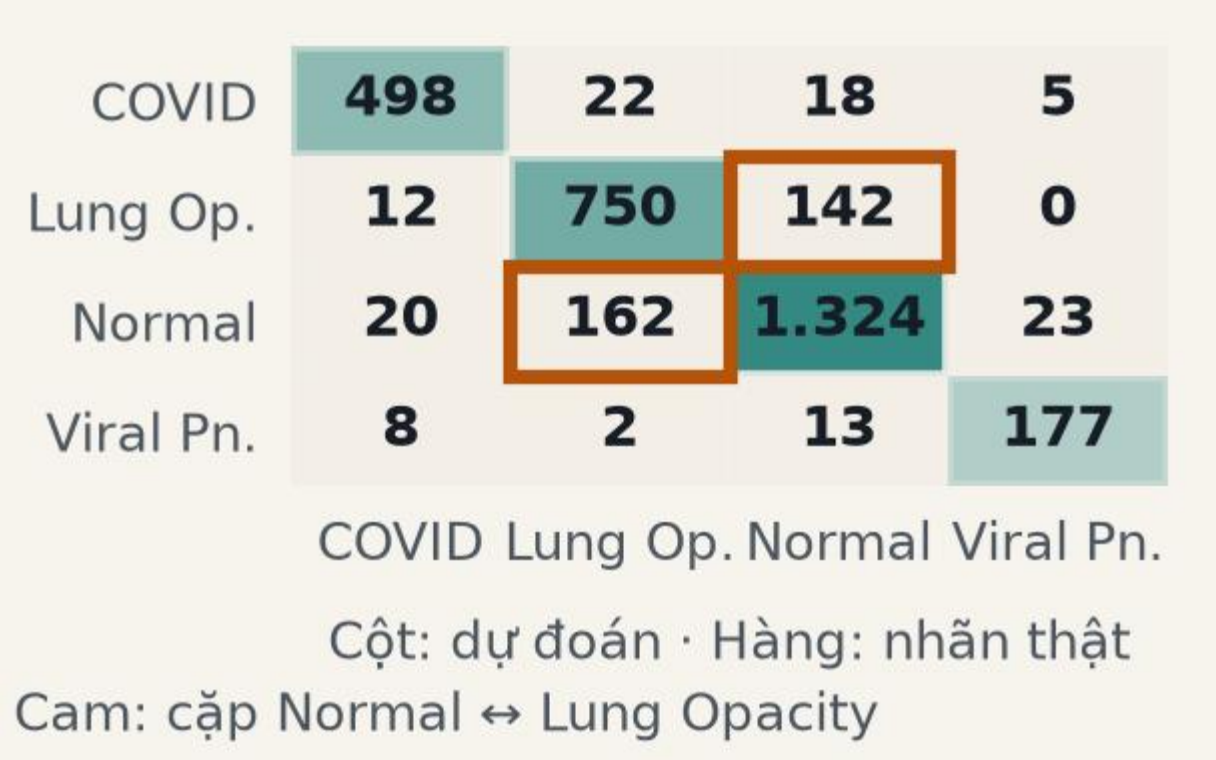
Test (3.176 ảnh)

0,8714

Chênh test − val = −0,0310

Quy tắc D4: Mọi lời giải thích về sự khác biệt giữa val và test đều là giả thuyết chưa kiểm chứng, không nêu nguyên nhân.

427 lỗi, 304 lỗi nằm giữa Normal và Lung_Opacity



Sai

427

trên 3.176 ảnh, tức 13,44%

Cặp Normal ↔ LO

304

71,19% số lỗi của toàn bộ tập test

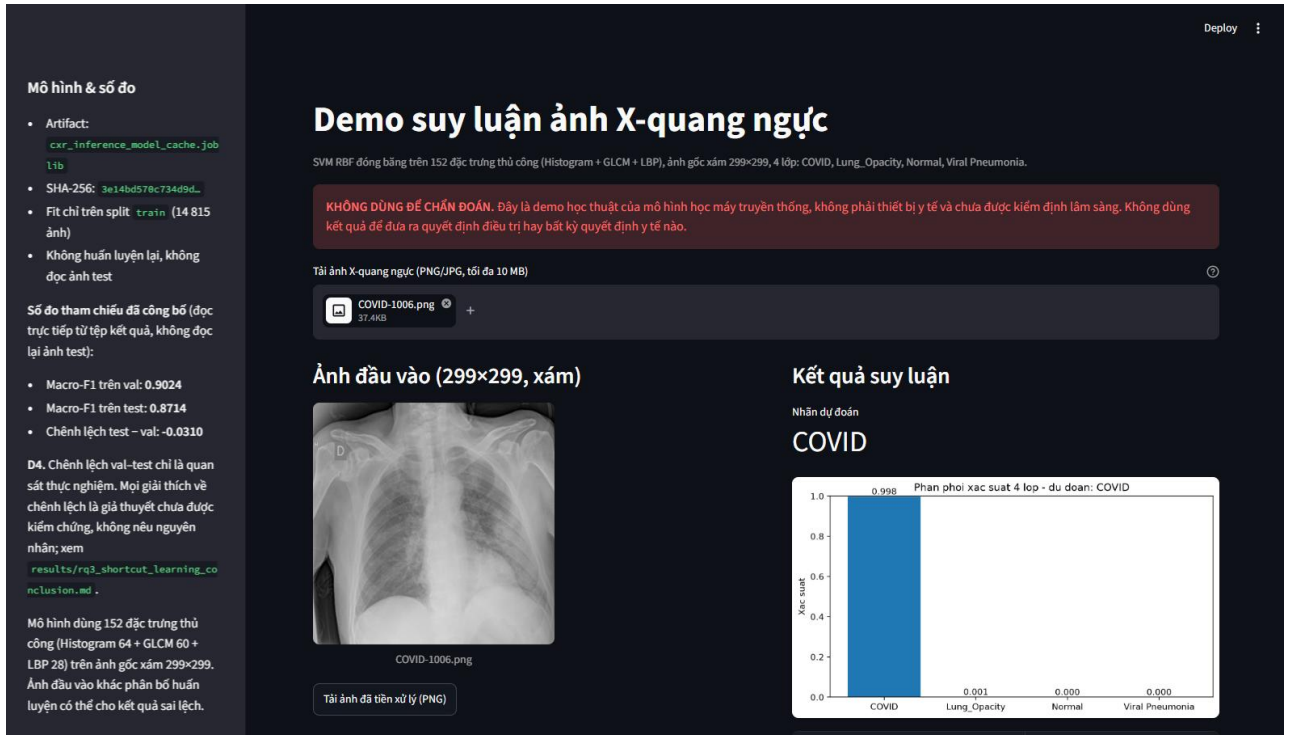
Precision thấp nhất

0,8013

của lớp Lung_Opacity trên tập test

Nguồn: results/final_test/metrics.json · results/final_test/final_test_report.json

Demo chạy 0,132 s một ảnh trên laptop i5-13420H



Trung vị 200 ảnh val, 3 lượt đo; p95 0,1445 s.

Giải mã
0,0033 s

Đặc trưng
0,1192 s

Suy luận
0,0092 s

Tổng mỗi ảnh
0,1318 s

Nguồn: results/demo_latency_sustained/latency.json · slides/assets/screenshot_demo.png

Hai ca minh hoạ: một đúng, một sai

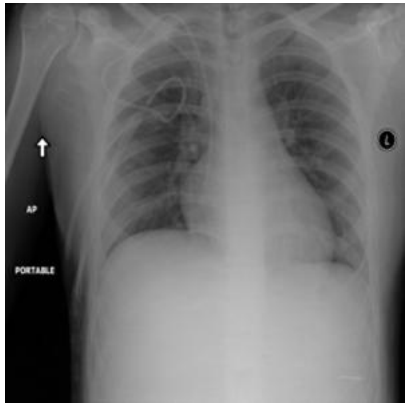


COVID-1006.png **Đúng**

Nhãn thật: COVID-19

Dự đoán: COVID-19

0,9979



Normal-9540.png **Sai**

Nhãn thật: Normal

Dự đoán: Lung Opacity

0,9700

Ca sai cho thấy mô hình vẫn tự tin ở mức cao trên một ca sai: Normal bị đoán thành Lung_Opacity với xác suất 0,9700. Cả hai ảnh thuộc split val.

Nguồn: results/rq2_ghep_svm_s42/preds_val.csv · slides/assets/case_correct.png, case_error.png

Giới hạn: 735 cặp gần trùng và không có patient_id

Gần trùng còn sót **735**	cặp nằm khác tập, trong đó 229 cặp lệch nhãn
Không có patient_id **thiếu**	cùng một bệnh nhân có thể nằm ở cả train và val
Nguồn ảnh chưa xác minh **chưa kiểm chứng**	tuổi nhi và ký hiệu thiết bị chưa được kiểm chứng
Val vừa chọn mô hình vừa báo cáo **lạc quan**	cùng một tập val vừa chọn cấu hình vừa báo cáo số
Ngoại suy ngoài bộ **chưa được đánh giá**	đổi nguồn hoặc tiền xử lý thì chưa ai đo lại

Nguồn: results/report_rq3/r5_gioi_han.md · results/threshold_v3.md mục 6 (R5) · report/06 mục 6.2

Không dùng để chẩn đoán

TUYÊN BỐ TRONG ỨNG DỤNG DEMO

KHÔNG DÙNG ĐỂ CHẨN ĐOÁN. Đây là demo học thuật của mô hình học máy truyền thống, không phải thiết bị y tế và chưa được kiểm định lâm sàng. Không dùng kết quả để đưa ra quyết định điều trị hay bất kỳ quyết định y tế nào.

Quy tắc D4: Mọi lời giải thích về sự khác biệt giữa val và test đều là giả thuyết chưa kiểm chứng, không nêu nguyên nhân.

Các con số trong đề tài này chỉ được đánh giá trên chính bộ dữ liệu và bước tiền xử lý đã dùng; đổi nguồn ảnh, thiết bị hoặc tiền xử lý thì chưa được đo lại.

Nguồn: demo/streamlit_app.py (DISCLAIMER) · results/final_test/r5_gioi_han.md (D4)

Ba điểm mang về và việc còn lại

T1 SVM RBF trên 152 đặc trưng thủ công đạt macro-F1 0,8714 trên 3.176 ảnh test; hai mốc nền trên validation: B0 = 0,1627, A0 = 0,2397.

T2 Trên validation, mô hình chỉ nhìn ngoài phổi đạt 0,8921, chênh ảnh gốc +0,0103 nhưng khoảng tin cậy của hiệu chứa 0.

T3 Kết quả chỉ có giá trị trong phạm vi bộ dữ liệu này, không dùng để chẩn đoán.

VIỆC CÒN LẠI

Bộ có patient_id

bộ dữ liệu lớn hơn, có mã bệnh nhân để chặn rò rỉ bệnh nhân

Gỡ gần trùng

tách nhóm cho cả cặp gần trùng, không chỉ trùng tuyệt đối

Kiểm chứng nguồn

xác minh tuổi nhi và thiết bị để giả thuyết thành phép thử

Nguồn: tổng hợp từ results/ và report/06

Cảm ơn

Mời hội đồng đặt câu hỏi.

Mã nguồn	github.com/tnduckhmt2411011-design/covid-radiography-classifier
Demo (Streamlit)	covid-xray-classifier.streamlit.app
Artifact mô hình	huggingface.co/duc16/cxr-svm-demo

Phân loại ảnh X-quang lồng ngực bằng học máy cổ điển và đánh giá nguy cơ shortcut learning trên bộ dữ liệu COVID-19 Radiography

DỰ PHÒNG · RQ1 từng seed và khoảng tin cậy

Histogram 64 **0,7829 ± 0,0013**	0,7842 · 0,7826 · 0,7817 CI 95% [0,7643; 0,8002]	seed 42 · 43 · 44
GLCM + LBP 88 **0,8156 ± 0,0023**	0,8175 · 0,8130 · 0,8164 CI 95% [0,7986; 0,8309]	seed 42 · 43 · 44
HOG 10.404 **0,7625 ± 0,0038**	0,7583 · 0,7656 · 0,7636 CI 95% [0,7459; 0,7787]	seed 42 · 43 · 44
Ghép 152 **0,8599 ± 0,0030**	0,8610 · 0,8622 · 0,8565 CI 95% [0,8452; 0,8732]	seed 42 · 43 · 44

Các seed của cùng một nhóm lệch nhau vài phần nghìn macro-F1; chênh lệch giữa các nhóm lớn hơn nhiều lần.

Nguồn: results/report_rq1/r1_per_seed.csv, r1_summary.csv · results/threshold_v3.md mục 1 (RQ1)

DỰ PHÒNG · RQ2 đầy đủ sáu bộ phân loại

SVM RBF	Gradient Boosting	Random Forest	Logistic Regression	k-NN	Decision Tree
0,9024	**0,8868**	**0,8582**	**0,8370**	**0,8242**	**0,7271**
[0,8909; 0,9129]	[0,8749; 0,8976]	[0,8432; 0,8716]	[0,8221; 0,8505]	[0,8075; 0,8397]	[0,7090; 0,7449]
1 seed	3 seed	3 seed	1 seed	1 seed	3 seed

Thứ tự sáu bộ trong báo cáo; SVM có 0,0442 chênh so với Random Forest và khoảng tin cậy không chứa 0.

Nguồn: results/report_rq2/r1_summary.csv · results/report_rq2/r1_per_seed.csv

DỰ PHÒNG · RQ3 đủ năm kịch bản

Gốc → gốc

0,9024

[0,8909; 0,9129]

Recall thấp nhất: 0,8494

Chỉ phổi → chỉ phổi

0,8490

[0,8333; 0,8625]

Recall thấp nhất: 0,8140

Ngoài phổi → ngoài phổi

0,8921

[0,8807; 0,9031]

Recall thấp nhất: 0,8317

Gốc → chỉ phổi

0,0723

[0,0677; 0,0770]

Recall thấp nhất: 0,0000

Gốc → ngoài phổi

0,2084

[0,1953; 0,2220]

Recall thấp nhất: 0,0049

Hai kịch bản cuối học trên ảnh gốc nhưng đánh giá trên ảnh đã bị che; chúng cho thấy tập huấn luyện và tập đánh giá là hai phân bố khác nhau. Quy ước A → B: huấn luyện trên ảnh dạng A, đánh giá trên ảnh dạng B.

Nguồn: results/report_rq3/r1_summary.csv · r4_sampling_error.csv

DỰ PHÒNG · 735 cặp gần trùng

THEO CẶP SPLIT

325
test ↔ train

335
train ↔ val

75
test ↔ val

Khoảng cách 4
665
cặp có Hamming = 4

Khoảng cách 2
70
cặp có Hamming = 2

Lệch nhãn
229
cặp gần trùng nhưng ghi nhãn khác nhau

Trong toàn bộ dữ liệu có 1.570 cặp có khoảng cách Hamming ≤ 4; 735 trong số đó nằm khác tập.

Nguồn: splits/README.md mục 3 · splits/split_v1.csv · results/eda

DỰ PHÒNG · Ma trận nhầm lẫn validation

Lỗi trên validation

349

ảnh dự đoán sai trên 3.174 ảnh

Lỗi cặp Normal ↔ LO

268

cặp nhầm lẫn đông nhất

Lỗi đồng thuận

240

SVM sai và GB, RF cũng sai (GB, RF lấy đa số 2/3 seed)

Lỗi p ≥ 0,80

138

39,5% số lỗi tự tin ở mức cao

138 lỗi trong tổng số 349 lỗi được mô hình dự đoán với xác suất từ 0,80 trở lên, nên nói “mô hình không biết mình sai” là không đúng trên toàn bộ tập lỗi.

Nguồn: results/error_analysis/val_misclassified_cases.csv, confusion_pairs_summary.csv

DỰ PHÒNG · Độ trễ đo trên 200 ảnh

Giải mã ảnh	**0,0033 s**	p95 0,0037 s
Rút đặc trưng	**0,1192 s**	p95 0,1302 s
Suy luận SVM	**0,0092 s**	p95 0,0096 s
Tổng mỗi ảnh	**0,1318 s**	p95 0,1445 s

ARTIFACT ĐÓNG BĂNG

Kích thước	7,84 MB
Số vector	6.180
Ảnh train	14.815
SHA-256	3e14bd570c734d9…
Máy	13th Gen Intel(R) Core(TM) i5-13420H

Đo trên 200 ảnh validation, 3 lượt, máy 13th Gen Intel(R) Core(TM) i5-13420H.

Nguồn: results/demo_latency_sustained/latency.json · outputs/k_v3_out